

Tugas 1

Pemrosesan Data untuk Analisis Big Data

STUDI KASUS

Dalam era Big Data, kualitas data menjadi faktor krusial dalam menghasilkan analisis yang akurat dan dapat dipercaya. Data yang diperoleh dari berbagai sumber sering kali mengandung permasalahan seperti nilai yang hilang (missing values), outlier, serta distribusi data yang tidak sesuai dengan asumsi statistik. Oleh karena itu, diperlukan proses data preprocessing yang sistematis untuk memastikan bahwa data siap digunakan dalam analisis lebih lanjut.

Seorang analis data diminta untuk melakukan pengolahan awal terhadap sebuah dataset yang diperoleh dari sumber terbuka, seperti UCI Machine Learning Repository atau Kaggle. Dataset yang digunakan dapat berupa data pada domain tertentu, seperti data cuaca, kesehatan, ekonomi, atau perilaku pelanggan. Dataset tersebut diakses secara langsung melalui URL menggunakan bahasa pemrograman seperti Python atau R.

Setelah data berhasil diambil, analis perlu melakukan eksplorasi awal untuk memahami struktur data, tipe variabel, serta kondisi kualitas data. Pada tahap ini, biasanya ditemukan berbagai permasalahan seperti adanya nilai yang hilang, distribusi data yang tidak normal, serta kemungkinan adanya nilai ekstrem (outlier) yang dapat mempengaruhi hasil analisis.

Selanjutnya, analis diharapkan melakukan serangkaian proses data preprocessing, yang meliputi penanganan missing values dengan metode yang sesuai, seperti penghapusan data atau imputasi menggunakan mean, median, atau metode lainnya. Selain itu, data juga perlu dinormalisasi agar memiliki skala yang seragam, menggunakan teknik seperti Min-Max Scaling atau Standardisasi (Z-score).

Setelah proses normalisasi, analis perlu mengidentifikasi keberadaan outlier menggunakan metode seperti boxplot dan pendekatan Interquartile Range (IQR). Outlier yang ditemukan harus dianalisis apakah perlu dipertahankan atau dihapus, disertai dengan alasan yang jelas.

Tahap berikutnya adalah melakukan uji normalitas data, misalnya menggunakan uji Shapiro-Wilk atau Kolmogorov-Smirnov, untuk mengetahui apakah

data telah memenuhi asumsi distribusi normal. Hasil uji ini menjadi dasar dalam menentukan metode analisis lanjutan yang tepat.

Tugas Mahasiswa

Berdasarkan studi kasus di atas, lakukan hal-hal berikut:

1. Pilih sebuah dataset dari UCI atau Kaggle yang relevan dengan bidang tertentu.
2. Ambil dataset tersebut secara langsung melalui URL menggunakan Python atau R.
3. Lakukan eksplorasi data awal untuk memahami struktur dan kualitas data.
4. Lakukan preprocessing data yang meliputi:
 - a). Penanganan missing values
 - b). Normalisasi data
 - c). Deteksi dan analisis outlier
5. Lakukan uji normalitas data dan interpretasikan hasilnya.
6. Tampilkan visualisasi yang menunjukkan kondisi data sebelum dan sesudah preprocessing.
7. Jelaskan bahwa data telah melalui proses cleansing dan siap digunakan untuk analisis lanjutan.

Luaran atau Output dari Pemrosesan data ini dimana Mahasiswa diharapkan menghasilkan:

- a). Script pemrograman (Python/R)
- b). Dataset yang telah dibersihkan
- c). Visualisasi data
- d). Laporan ilmiah yang menjelaskan proses dan hasil analisis

Penulisan Laporan

Laporan disusun secara sistematis dengan struktur:

- | | |
|-------|---------------------------------|
| BAB 1 | Pendahuluan |
| BAB 2 | Deskripsi dataset |
| BAB 3 | Metodologi preprocessing |
| BAB 4 | Hasil dan Penjelasan secukupnya |

